

AGH

**AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE**

Metody numeryczne

Układy równań liniowych

**Dr hab.. inż. Jerzy Baranowski
Katedra Automatyki i Robotyki**

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \left[\begin{array}{c|cc} a_1 & a_2 & a_3 \end{array} \right]$$

Iloczyn macierz wektor

$$Ax = \sum_{j=1}^n x_j a_j$$

$$\begin{bmatrix} b \\ \vdots \\ b_n \end{bmatrix} = \begin{bmatrix} a_1 & | & a_2 & | & \cdots & | & a_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix} + x_2 \begin{bmatrix} a_2 \\ \vdots \\ a_n \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_n \\ \vdots \\ a_n \end{bmatrix}.$$

Rząd macierzy

- Rzędem macierzy nazywamy liczbę liniowo niezależnych kolumn

Macierz odwrotna

- Macierz kwadratowa A o wymiarach $m \times m$
- Macierz odwrotna do A to taka macierz, że

$$A \cdot Z = I$$

- Macierz odwrotną oznaczamy A^{-1}
- Zachodzi $A^{-1} \cdot A = A \cdot A^{-1} = I$
- Macierz odwrotna istnieje tylko jeżeli rząd jest równy m

Macierz Sprzężona (Transponowana)

- Macierz, w której elementy zamieniamy na sprzężone, a kolumny zamieniamy na wiersze

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{22} & a_{32} \end{bmatrix} \Rightarrow A^* = \begin{bmatrix} \bar{a}_{11} & \bar{a}_{21} & \bar{a}_{31} \\ \bar{a}_{12} & \bar{a}_{22} & \bar{a}_{32} \end{bmatrix}$$

- Jeżeli macierz jest rzeczywista, to sprzężenie jest transpozycją

Iloczyn skalarny

- Iloczyn skalarny wektorów

$$x^*y = \sum_{i=1}^m \bar{x}_i y_i$$

- Długość wektora

$$\|x\| = \sqrt{x^*x} = \left(\sum_{i=1}^m |x_i|^2 \right)^{1/2}$$

- Kąt między wektorami

$$\cos \alpha = \frac{x^*y}{\|x\| \|y\|}$$

Wektory ortogonalne

- Dwa wektory nazywamy ortogonalnymi, jeżeli iloczyn skalarny między nimi jest równy 0

$$x^*y = 0$$

- Zbiór S wektorów, jest ortogonalny, jeżeli wektory są parami ortogonalne

$$x, y \in S, x \neq y \Rightarrow x^*y = 0$$

- Wektory ortogonalne są liniowo niezależne
- Wektory ortogonalne o długości 1 nazywamy ortonormalnymi

Macierz Unitarna (Ortogonalna)

- Macierz unitarna (ortogonalna), to taka, której sprzężenie (transpozycja) jest jej odwrotnością

$$\bar{Q^*} = Q^{-1}$$

- Kolumny macierzy unitarnej tworzą zbiór wektorów ortonormalnych

$$\begin{bmatrix} q_1^* \\ \hline q_2^* \\ \hline \vdots \\ \hline q_m^* \end{bmatrix} \begin{bmatrix} q_1 & q_2 & \cdots & q_m \end{bmatrix} = \begin{bmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{bmatrix}$$

Kilka słów o normach

- Norma wektora to funkcja, która każdemu wektorowi przyporządkowuje liczbę nieujemną

$$\| \cdot \| : X \rightarrow [0, \infty)$$

- Norma jest pewnym uogólnieniem długości wektora

Aksjomaty normy

- Norma równa 0 oznacza, że wektor jest wektorem zerowym

$$\|x\| = 0 \Rightarrow x = 0$$

- Skalowanie wektora skaluje normę

$$\|\alpha x\| = |\alpha| \|x\|$$

- Nierówność trójkąta

$$\|x + y\| \leq \|x\| + \|y\|$$

Norma jako odległość

- Odległość między dwoma punktami w danej normie to norma wektora jaki poprowadzono między nimi

Norma w definicji zbiorów

- Przy użyciu normy łatwo zdefiniować zbiory, zwłaszcza w ogólniejszej formie, np.
 - Kula

$$K(x_0, r) = \{x : \|x - x_0\| \leq r\}$$

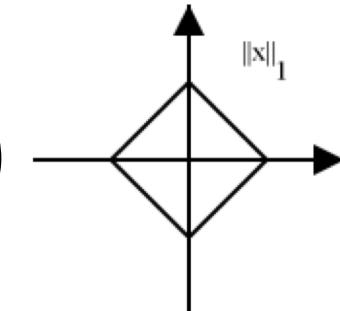
- Sfera

$$S(x_0, r) = \{x : \|x - x_0\| = r\}$$

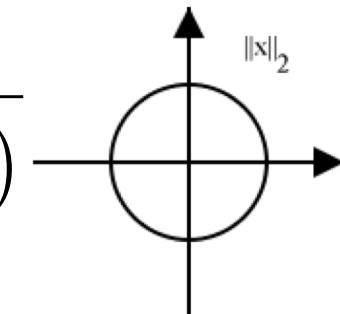
Kula nie musi być okrągła!

Kształt kuli zależy od normy

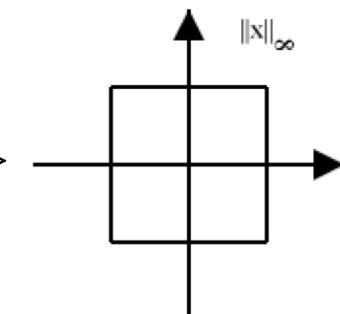
$$\|\mathbf{x}\|_1 = (|x_1| + |x_2| + \dots + |x_n|)$$



$$\|\mathbf{x}\|_2 = \sqrt{(|x_1|^2 + |x_2|^2 + \dots + |x_n|^2)}$$



$$\|\mathbf{x}\|_\infty = \max\{|x_i| : i = 1, \dots, n\}$$



Norma macierzy

- Istnieją dwa rodzaje norm macierzowych
 - indukowana
 - elementowa

Norma indukowana

- To taka norma, która mówi nam jak silnie dana macierz wpływa na wektor

$$\begin{aligned}\|A\| &= \max\{\|Ax\| : x \in R^n \text{ gdzie } \|x\| = 1\} \\ &= \max \left\{ \frac{\|Ax\|}{\|x\|} : x \in R^n \text{ gdzie } x \neq 0 \right\}.\end{aligned}$$

- Przykłady:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

Normy elementowe

- To normy, które definiowane są wprost w oparciu o parametry macierzy

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\text{trace}(A^* A)}$$

$$\|A\|_{\max} = \max\{|a_{ij}|\}$$

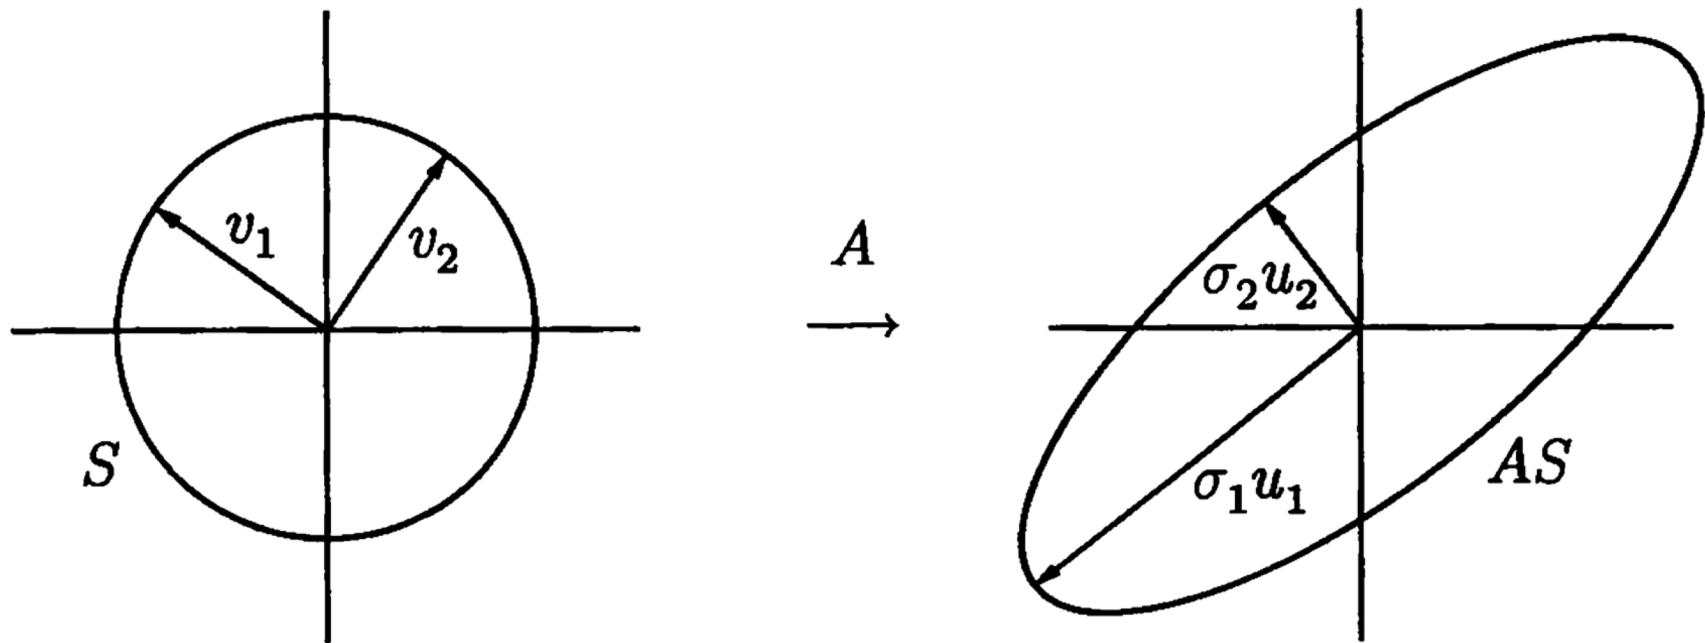
Równoważność norm

- Wszystkie normy w przestrzeniach skończenie wymiarowych są równoważne

$$c\|x\|_1 \leq \|x\|_2 \leq C\|x\|_1$$

SVD – Rozkład na wartości singularne

- Rozważmy macierz jako przekształcenie geometryczne



SVD – Rozkład na wartości singularne

- Interpretacja macierzowa

$$A = \begin{bmatrix} & & & & \\ & v_1 & v_2 & \cdots & v_n \\ & & & & \end{bmatrix} = \begin{bmatrix} & & & & \\ u_1 & u_2 & \cdots & u_n & \\ & & & & \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix}$$

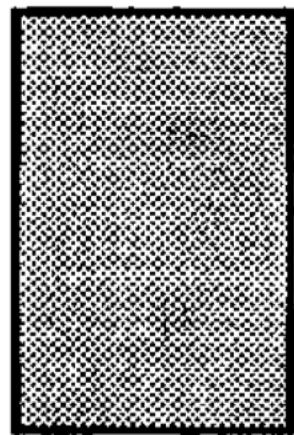
lub w skrócie

$$AV = \hat{U}\hat{\Sigma}$$

SVD – Rozkład na wartości singularne

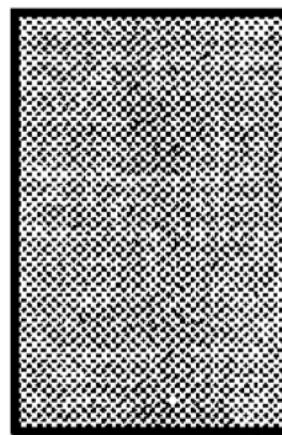
- Macierze \hat{U} i V są unitarne

$$A = \hat{U} \hat{\Sigma} V^*$$



A

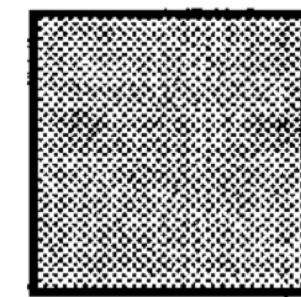
$=$



\hat{U}



$\hat{\Sigma}$



V^*

Wartości singularne

- Dodatnie, uporządkowane liczby rzeczywiste

$$\begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix}$$

Ważne cechy wartości singularnych

- Rząd macierzy to liczba niezeroowych wartości singularnych
- Normy macierzy wyrażają się przez wartości singularne

$$\|A\|_2 = \sigma_1$$

$$\|A\|_F = \sqrt{\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_r^2}$$

- Wyznacznik macierzy kwadratowej jest iloczynem wartości singularnych
- Wartości singularne macierzy odwrotnej są odwrotnościami wartości singularnych

Prosty układ równań liniowych

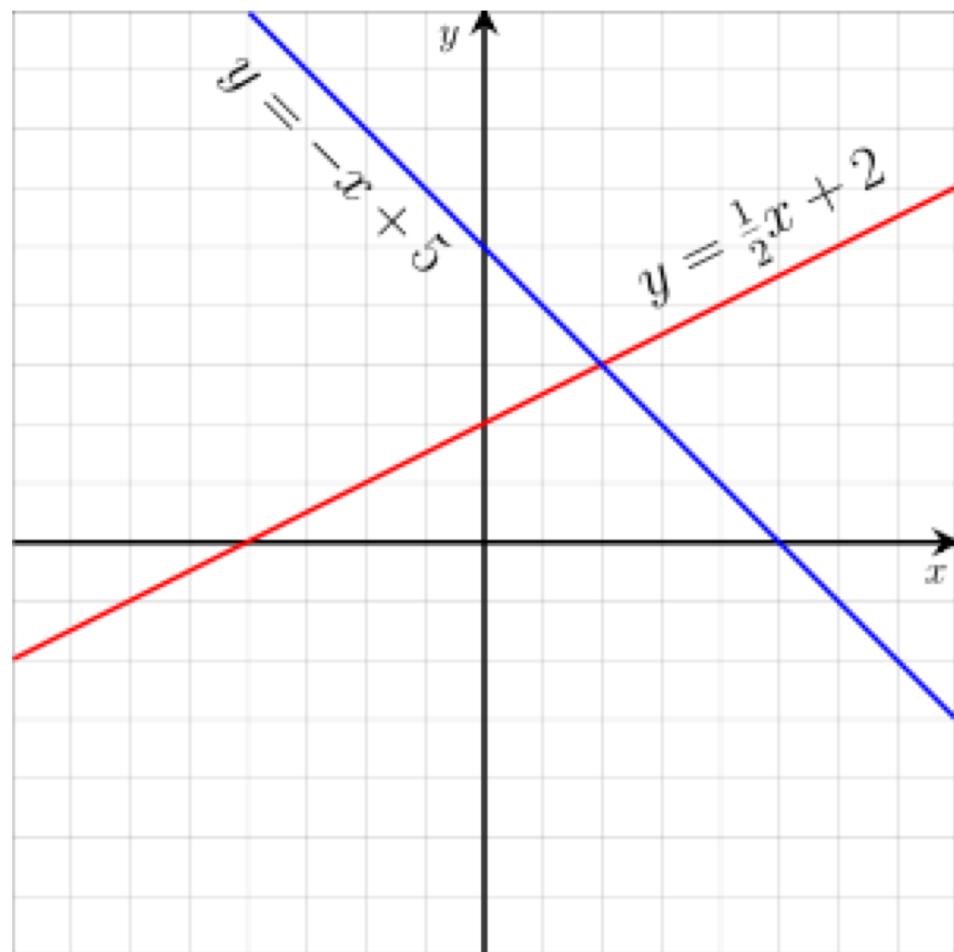
$$x + y = 5$$

$$-\frac{1}{2}x + y = 2$$

$$\frac{3}{2}x = 3$$

$$x = 2$$

$$y = 3$$



Układ n równań z n niewiadomymi

$$\begin{array}{ccccccc} a_{11}x_1 & + & a_{12}x_2 & + & \dots & + & a_{1n}x_n = b_1, \\ a_{21}x_1 & + & a_{22}x_2 & + & \dots & + & a_{2n}x_n = b_2, \\ \vdots & & \vdots & & \ddots & & \vdots \\ a_{n1}x_1 & + & a_{n2}x_2 & + & \dots & + & a_{nn}x_n = b_n. \end{array}$$

Postać macierzowa układu równań

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

Lub w skrócie

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

Kiedy układ równań ma rozwiązanie?

- Twierdzenie Kronekera-Capelliego:
Układ równań z m niewiadomymi ma rozwiązanie wtedy i tylko wtedy gdy macierze A i $[A \mid b]$ mają ten sam rząd. Rozwiązanie jest unikalne gdy ten rzząd wynosi m . W przeciwnym wypadku jest ich nieskończenie wiele.

Uwarunkowanie układu równań

- Dla układu m równań z m niewiadomymi można policzyć stałą uwarunkowania κ i wynosi ona

$$\kappa = \frac{\sigma_1}{\sigma_n}$$

Jakie układy równań łatwo rozwiązać?

- Układy z macierzą trójkątną

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22} & a_{23} & \dots & a_{2n} \\ 0 & 0 & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & a_{nn} \end{bmatrix}$$

Układ z macierzą trójkątną

- Bardzo proste wzory

$$x_n = \frac{b_n}{a_{nn}}$$

$$x_i = \frac{b_i - \sum_{j=1}^n a_{ij}x_j}{a_{ii}}, \quad i = n-1, n-2, \dots, 1$$

- Mała złożoność $O(n^2)$

Zamiana układu równań - dekompozycja

- Aby rozwiązać układ równań stosujemy dekompozycję macierzy

$$A = CD$$

Wtedy rozwiązanie układu równań ma postać

$$Ax = b$$

$$CDx = b$$

$$\begin{cases} Cy = b \\ Dx = y \end{cases}$$

Jeżeli D jest trójkątna, a C trójkątna lub łatwa do odwrócenia układ równań można łatwo rozwiązać.

Rozkład LU

- Najpopularniejszy sposób rozwiązywania układów równań liniowych

$$A = LU$$

- L jest trójkątna dolna (z 1 na przekątnej),
U jest trójkątna górną

Eliminacja Gaussa

- Rozkład LU konstruuje się przez eliminację Gaussa

$$\underbrace{L_{m-1} \cdots L_2 L_1}_{L^{-1}} A = U$$

$$L = L_1^{-1} L_2^{-1} \cdots L_{m-1}^{-1}$$

$$\begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \end{bmatrix} \xrightarrow{L_1} \begin{bmatrix} \times & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \end{bmatrix} \xrightarrow{L_2} \begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \end{bmatrix} \xrightarrow{L_3} \begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \mathbf{0} & \times & \times & \times \end{bmatrix}$$

A $L_1 A$ $L_2 L_1 A$ $L_3 L_2 L_1 A$

Konstrukcja macierzy L_k

$$L_k = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & -\ell_{k+1,k} & 1 & \\ & \vdots & & \ddots \\ & -\ell_{mk} & & 1 \end{bmatrix}$$

$$\ell_{jk} = \frac{x_{jk}}{x_{kk}} \quad (k < j \leq m)$$

$$L = L_1^{-1} L_2^{-1} \cdots L_{m-1}^{-1} = \begin{bmatrix} 1 & & & & \\ \ell_{21} & 1 & & & \\ \ell_{31} & \ell_{32} & 1 & & \\ \vdots & \vdots & \ddots & \ddots & \\ \ell_{m1} & \ell_{m2} & \cdots & \ell_{m,m-1} & 1 \end{bmatrix}$$

Algorytm

$$U = A, \ L = I$$

for $k = 1$ **to** $m - 1$

for $j = k + 1$ **to** m

$$\ell_{jk} = u_{jk}/u_{kk}$$

$$u_{j,k:m} = u_{j,k:m} - \ell_{jk} u_{k,k:m}$$

Złożoność obliczeniowa $O(2/3 m^3)$

Niestabilność

- Jeżeli w macierzy będą 0 w niewłaściwych miejscach to eliminacja będzie niemożliwa
- Jeżeli zamiast zer będą bardzo małe liczby jest duży potencjał na błędy numeryczne.

Przykład

$$A = \begin{bmatrix} 10^{-20} & 1 \\ 1 & 1 \end{bmatrix}$$

Rozkład LU

$$L = \begin{bmatrix} 1 & 0 \\ 10^{20} & 1 \end{bmatrix} \quad U = \begin{bmatrix} 10^{-20} & 1 \\ 0 & 1 - 10^{20} \end{bmatrix}$$

Zaokrąglenia

$$\tilde{L} = \begin{bmatrix} 1 & 0 \\ 10^{20} & 1 \end{bmatrix}, \quad \tilde{U} = \begin{bmatrix} 10^{-20} & 1 \\ 0 & -10^{20} \end{bmatrix}$$

Iloczyn

$$\tilde{L}\tilde{U} = \begin{bmatrix} 10^{-20} & 1 \\ 1 & 0 \end{bmatrix} \quad A \neq \tilde{L} \cdot \tilde{U}$$

Pivoting (przestawianie)

Wybieramy wiersz zaczynający się od największego elementu i zamieniamy go z bieżącym

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \mathbf{x_{ik}} & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \\ \times & \times & \times & \times \end{bmatrix} \xrightarrow{P_1}
 \begin{bmatrix} \times & \times & \times & \times & \times \\ \mathbf{x_{ik}} & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \\ \times & \times & \times & \times \\ \mathbf{\times} & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \\ \times & \times & \times & \times \end{bmatrix} \xrightarrow{L_1}
 \begin{bmatrix} \times & \times & \times & \times & \times \\ \mathbf{x_{ik}} & \times & \times & \times \\ 0 & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \\ 0 & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \\ 0 & \mathbf{\times} & \mathbf{\times} & \mathbf{\times} \end{bmatrix}$$

$$L_{m-1} P_{m-1} \cdots L_2 P_2 L_1 P_1 A = U.$$



AGH

Przykład

$$A = \begin{bmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{bmatrix}$$

$$P_1 \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ 4 & 3 & 3 & 1 \\ 2 & 1 & 1 & 0 \\ 6 & 7 & 9 & 8 \end{bmatrix}$$

$$L_1 \begin{bmatrix} 1 & 1 \\ -\frac{1}{2} & 1 \\ -\frac{1}{4} & 1 \\ -\frac{3}{4} & 1 \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ 4 & 3 & 3 & 1 \\ 2 & 1 & 1 & 0 \\ 6 & 7 & 9 & 8 \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ -\frac{1}{2} & -\frac{3}{2} & -\frac{3}{2} \\ -\frac{3}{4} & -\frac{5}{4} & -\frac{5}{4} \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \end{bmatrix}$$

$$P_2 \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ -\frac{1}{2} & -\frac{3}{2} & -\frac{3}{2} \\ -\frac{3}{4} & -\frac{5}{4} & -\frac{5}{4} \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{3}{4} & -\frac{5}{4} & -\frac{5}{4} \\ -\frac{1}{2} & -\frac{3}{2} & -\frac{3}{2} \end{bmatrix}$$

$$L_2 \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ \frac{3}{7} & 1 \\ \frac{2}{7} & 1 \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{3}{4} & -\frac{5}{4} & -\frac{5}{4} \\ -\frac{1}{2} & -\frac{3}{2} & -\frac{3}{2} \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{2}{7} & \frac{4}{7} & \frac{2}{7} \\ -\frac{6}{7} & -\frac{2}{7} & -\frac{2}{7} \end{bmatrix}$$

Przykład cd

$$P_3 \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{2}{7} & \frac{4}{7} \\ -\frac{6}{7} & -\frac{2}{7} \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{6}{7} & -\frac{2}{7} \\ -\frac{2}{7} & \frac{4}{7} \end{bmatrix}$$

$$L_3 \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \\ & & -\frac{1}{3} \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{6}{7} & -\frac{2}{7} \\ -\frac{2}{7} & \frac{4}{7} \end{bmatrix} = \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{6}{7} & -\frac{2}{7} \\ \frac{2}{3} \end{bmatrix}$$

$$\begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \\ & & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{bmatrix} = \begin{bmatrix} 1 & & & \\ \frac{3}{4} & 1 & & \\ \frac{1}{2} & -\frac{2}{7} & 1 & \\ \frac{1}{4} & -\frac{3}{7} & \frac{1}{3} & 1 \end{bmatrix} \begin{bmatrix} 8 & 7 & 9 & 5 \\ \frac{7}{4} & \frac{9}{4} & \frac{17}{4} \\ -\frac{6}{7} & -\frac{2}{7} \\ \frac{2}{3} \end{bmatrix}$$

P A L U

Algorytm

$$U = A, \ L = I, \ P = I$$

for $k = 1$ **to** $m - 1$

 Select $i \geq k$ to maximize $|u_{ik}|$

$u_{k,k:m} \leftrightarrow u_{i,k:m}$ (interchange two rows)

$\ell_{k,1:k-1} \leftrightarrow \ell_{i,1:k-1}$

$p_{k,:} \leftrightarrow p_{i,:}$

for $j = k + 1$ **to** m

$$\ell_{jk} = u_{jk}/u_{kk}$$

$$u_{j,k:m} = u_{j,k:m} - \ell_{jk} u_{k,k:m}$$

Uwagi o LU

- LU z pivotingiem jest stabilna wstecznie (stała uwarunkowania mnoży rząd błędu) dla wszystkich praktycznych macierzy
- Istnieją macierze, w których elementy A i U mają różne rzędy wielkości (U dużo większy), takie macierze muszą mieć bardzo specyficzną strukturę i praktycznie nie występują w zastosowaniach

Rozkład Choleskiego

- Dla macierzy symetrycznych dodatnio określonych istnieje wariant LU

$$A = R^*R, \quad r_{jj} > 0$$

- Przy czym R jest trójkątna górną.
Złożoność obliczeniowa wynisi $O(1/3m^3)$

Rozkład QR

- Innym popularnym rozkładem jest rozkład QR

$$A = \hat{Q}\hat{R}$$

$$\left[\begin{array}{c|c|c|c} & a_1 & a_2 & \cdots & a_n \end{array} \right] = \left[\begin{array}{c|c|c|c} & q_1 & q_2 & \cdots & q_n \end{array} \right] \left[\begin{array}{cccc} r_{11} & r_{12} & \cdots & r_{1n} \\ r_{22} & & & \vdots \\ \ddots & & & \\ r_{nn} & & & \end{array} \right]$$

przy czym \hat{Q} jest macierzą ortogonalną

Rozwiążanie układu równań rozkładem QR

$$Rx = Q^*b$$

Wyliczamy faktoryzację

Wyliczamy prawą stronę

Rozwiązuje my układ równań z macierzą trójkątną

Uwagi o QR

- Działa również dla macierzy prostokątnych
- Złożoność obliczeniowa $O(2mn^2 - 2/3n^3)$
- Metoda stabilna wstecznie
- Stosowana głównie do problemu najmniejszych kwadratów
- Dwa algorytmy:
 - Ortogonalizacja Grama-Schmidt'a buduje macierz trójkątną R tak aby Q była ortogonalna
 - Triangularyzacja Hauseholdera buduje macierz ortogonalną Q aby R była trójkątna.

Jak się to robi w praktyce

